

Geoestadística No Paramétrica: Representando información espacial de forma flexible

Ing. Sergio Castillo Páez, PhD.

Universidad de las Fuerzas Armadas ESPE, Ecuador
Universidad de Vigo, España



29 Junio 2018

- 1 Introducción
- 2 Modelización geoestadística
- 3 Estimación Paramétrica
- 4 Geoestadística No Paramétrica

- **Geoestadística:** Proporciona modelos y métodos para el análisis de información de procesos continuos asociados a posiciones espaciales.
- **Algunos ejemplos:**
 - Medioambiente: Mapas de Riesgo de Contaminación (Fernandez Casal et al, 2017)
 - Econometría espacial: *Estudios de precios de bienes raíces, crecimiento urbano, selección de localización de negocios, etc.* (G. Arbia y H. Baltagi, 2009)
 - Finanzas: *Optimización de portafolios de inversión mediante kriging* (C. Oliveira et al., 2012)
 - Marketing: *Geomarketing, análisis de políticas de marketing* (E. Bradlow et al., 2005)
 - En estudios sociales: *Mapas de tasas de crimen en una ciudad* (G. Fernández-Avilés Calderón, 2008)

Introducción

Idea clave: Observaciones más cercanas son similares entre sí, y a medida que la separación entre ellas aumenta, su correlación disminuye (*dependencia espacial*).




Fig 1: Zinc (ppm) en las riberas del río Meuse. (Fig. Izq.), Dispersión respecto a la dirección Este (Fig. Cent.) y Norte (Fig. Der.) y curvas de regresión no paramétrica.

```
1 library(sp); data(meuse)
2 coordinates(meuse)= ~x+y
3 spplot(meuse, "zinc")
4 plot(meuse@coords[,1], meuse@data$zinc, xlab = "Direccion Este", ylab = " log(ppm)")
5 lines(lowess(meuse@coords[,1], meuse@data$zinc), col = 2)
```

Modelización geoestadística

- Proceso espacial: $\{Y(\mathbf{x}), \mathbf{x} \in D \subset \mathbb{R}^d\}$, con dominio D continuo.

Modelo con tendencia no constante:

$$Y(\mathbf{x}) = \mu(\mathbf{x}) + \varepsilon(\mathbf{x}), \quad (1)$$

- $\mu(\cdot)$ función tendencia (determinística).
- $\varepsilon(\cdot)$ proceso de error estacionario de segundo orden, de media cero y covariograma:

$$C(\mathbf{u}) = \text{Cov}(\varepsilon(\mathbf{x}), \varepsilon(\mathbf{x} + \mathbf{u}))$$

- Usualmente, la dependencia se modela a través del variograma:

$$\gamma(\mathbf{u}) = \frac{1}{2} \text{Var}(\varepsilon(\mathbf{x}) - \varepsilon(\mathbf{x} + \mathbf{u})) \quad (2)$$



- $C(\mathbf{u})$ y $\gamma(\mathbf{u})$ dependen solo del salto u , además:

$$\gamma(\mathbf{u}) = \sigma^2 - C(\mathbf{u}).$$

Modelización geoestadística

Características del variograma

- **Efecto nugget (c_0):** Comportamiento cerca del origen.
- **Umbral (σ^2):** Comportamiento en el límite del salto.
- **Umbral parcial (c_1):** $\sigma^2 - c_0$.
- **Rango práctico (a):** Distancia mínima a la cual $\gamma(\mathbf{u}) = 0.95\sigma^2$.
- **Anisotropía:** Cuando la forma de $\gamma(\mathbf{u})$ dependiendo de la dirección de \mathbf{u} .
Si $\gamma(\mathbf{u}) = \gamma(\|\mathbf{u}\|)$ se dice *isotrópico*.



Ejemplos de variogramas y covariogramas.

- *Regresión kriging*: Estimación paramétrica de la tendencia y la dependencia basada en residuos.
 - 1 Obtener una estimación inicial de la tendencia $\hat{\mu} = \mathbf{X}\hat{\beta}_{mco}$.
 - 2 Calcular los residuos o errores estimados: $\hat{\varepsilon} = \mathbf{Y} - \hat{\mu}$.
 - 3 Ajustar un variograma válido $\hat{\gamma}(\mathbf{u})$ construido a partir de $\hat{\varepsilon}$.
 - 4 Se reestima la función $\mu(\cdot)$:

$$\hat{\beta}_{mcge} = (\mathbf{X}^t \hat{\Sigma}^{-1} \mathbf{X})^{-1} \mathbf{X}^t \hat{\Sigma}^{-1} \mathbf{Y}$$

donde $\hat{\Sigma}$ se obtiene a partir de $\hat{\gamma}(\mathbf{u})$.


- Este proceso se puede repetir de forma iterativa (Algoritmo Neuman - Jacobson)

Estimación Paramétrica

Estimación del variograma

Para estimar $\gamma(\cdot)$ se recurre al *análisis estructural*:

- 1 Obtener un estimador piloto no paramétrico (p.e. estimador empírico).
- 2 Selección y ajuste de un modelo válido de variograma (p.e. modelo exponencial)
- 3 Diagnóstico del variograma ajustado (p.e. por Validación cruzada)



Estimación paramétrica del variograma de los residuos a partir de un modelo Exponencial

```
1 library (gstat)
2 vgm <- variogram(log(zinc) ~ sqrt(dist), meuse)
3 fit.vgm <- fit.variogram(vgm, model = vgm(1, "Exp", 300, 1))
4 plot(vgm, fit.vgm, main = " ", xlab = "metros", ylab="semivarianzas", col = 1)
```


Geoestadística No Paramétrica


Estimación Paramétrica vs. No Paramétrica

Enfoque Paramétrico

- Expuestos a problemas de mala especificación.
- La variabilidad de los residuos subestima la variabilidad del proceso.

Enfoque No Paramétrico

- Obtienen estimaciones más flexibles.
- Facilitan la selección de un modelo.
- Requieren la selección de un parámetro de suavizado (ventana).



Tendencia estimada paramétricamente, a partir de la distancia a la orilla del río (log ppm zinc)

```
1 model.gstat <- gstat(formula = log(zinc) ~ sqrt(dist), data = meuse, model = fit.vgm)
2 pred.gstat <- predict(model.gstat, meuse.grid, BLUE = TRUE) #prediccion de tendencia por
  mínimos cuadrados generalizados
3 trend.pred <- pred.gstat$var1.pred
4 spoints(meuse.grid$x, meuse.grid$y, trend.pred)
```

Geoestadística No Paramétrica

Estimación lineal local de la tendencia

Se obtiene como la solución para α del siguiente problema:

$$\min_{\alpha, \beta} \sum_{i=1}^n \left\{ Y(\mathbf{x}_i) - \alpha - \beta^T (\mathbf{x}_i - \mathbf{x}) \right\}^2 K_{\mathbf{H}}(\mathbf{x}_i - \mathbf{x}).$$

De forma explícita:

$$\hat{\mu}_{\mathbf{H}}(\mathbf{x}) = \mathbf{e}_1^t (\mathbf{X}_{\mathbf{x}}^t \mathbf{W}_{\mathbf{x}} \mathbf{X}_{\mathbf{x}})^{-1} \mathbf{X}_{\mathbf{x}}^t \mathbf{W}_{\mathbf{x}} \mathbf{Y} = s_{\mathbf{x}}^t \mathbf{Y},$$

donde $\mathbf{e}_1 = (1, 0, \dots, 0)$, $\mathbf{X}_{\mathbf{x}}$ es la matriz cuya i -ésima fila es igual a $(1, (\mathbf{x}_i - \mathbf{x})^t)$, $\mathbf{W}_{\mathbf{x}} = \text{diag} \{K_{\mathbf{H}}(\mathbf{x}_1 - \mathbf{x}), \dots, K_{\mathbf{H}}(\mathbf{x}_n - \mathbf{x})\}$, $K_{\mathbf{H}}(\mathbf{u}) = |\mathbf{H}|^{-1} K(\mathbf{H}^{-1}\mathbf{u})$, siendo K una función tipo núcleo d -dimensional, y \mathbf{H} la matriz ventana $d \times d$ simétrica no singular.

Se puede expresar como suavizado lineal de los datos $(\mathbf{x}_i, Y(\mathbf{x}_i))$:

$$\hat{\mu} = \mathbf{S} \mathbf{Y}, \text{ donde } s_{\mathbf{x}}^t \text{ es la } i\text{-ésima fila de la matriz de suavizado } \mathbf{S}.$$

Observaciones


- La ventana **H** se selecciona mediante criterios que deben tomar en cuenta la dependencia espacial
- El estimador lineal local reduce el efecto frontera, y también se puede aplicar para estimar el variograma.
- Se cuenta con un procedimiento NP para corregir el sesgo en la variabilidad de los residuos
- Funciones programadas en el paquete *npsp* de *R*

Simulación del efecto del sesgo en el variograma, debido al uso de residuos

Aplicación a datos: Meuse

Estimación lineal local $\hat{\mu}$ piloto y final


Estimación $\hat{\gamma}$ residual y Modelo S-B ajustado a $\tilde{\gamma}$



- Ejemplo completo de aplicación del paquete **npsp** en **R**:
- Datos de precipitación mensual en EEUU
- <https://rubenfcasal.github.io/npsp/articles/npsp.html>

 Cressie, N. (1993) *Statistics for Spatial Data*. Wiley.

 Fernández-Casal R, Francisco-Fernández M (2014) *Nonparametric bias-corrected variogram estimation under non-constant trend*. Stoch Environ Res Risk Assess 28.

 Fernández-Casal, R., Castillo-Páez, S., y Francisco-Fernández, M. (2017) *Nonparametric geostatistical risk mapping*, Stoch Environ Res Risk Assess.

 Pebesma, E.J. (2004) *Multivariable geostatistics in S: the gstat package*. Computers & Geoscience 30: 683-691.

GRACIAS